Mapeando YouTube fuera de la burbuja

Embeddings multimodales de videos con EmbeddingGemma 2

[**PENDIENTE:** Integrantes]
IIC2433 Minería de Datos — 2026-2

28 de octubre de 2026

Resumen

[**PENDIENTE:** Escribir al final (5–6 líneas): problema, datos, método, resultado principal.] Representamos 34.788 videos de YouTube en un espacio vectorial común usando EmbeddingGemma 2, a partir de su texto (título, tags y descripción) y de su miniatura. Sobre el texto, el modelo supera a dos baselines (TF-IDF y MiniLM) en todas las métricas. Sobre los 34.771 videos con miniatura, la imagen por sí sola es casi tan informativa como el texto, y su fusión tardía mejora la recuperación de la categoría temática (kNN de 0,798 a 0,838). Además, como imagen y texto comparten el espacio, la miniatura permite etiquetar videos sin entrenamiento (zero-shot): en el 60 % de los casos, alguna de las 5 etiquetas predichas es una etiqueta real.

1. Introducción

[**PENDIENTE:** Motivación: las plataformas recomiendan contenido cercano a lo que ya consumimos (burbujas de filtro). Pregunta: ¿podemos construir un mapa del contenido de YouTube que permita, más adelante, recomendar videos *fuera* de esa zona? Contribuciones: (1) pipeline de datos YT-8M + API, (2) comparación de representaciones de texto, imagen y multimodales, (3) etiquetado zero-shot desde la miniatura.]

2. Datos

2.1. YouTube-8M

Usamos la versión 2 (2018) de YouTube-8M [1], con ∼6,1 millones de videos. Del split de entrenamiento descargamos una muestra aleatoria de ∼1 %: 41 archivos (*shards*), seleccionados de forma determinística por el hash MD5 de su nombre.

Sea $\mathcal{I} = \{1, \ldots, N\}$ el conjunto de videos de la muestra, con $N = 41.393$. Construimos la tabla Y, cuya fila i es

$$y_i = (p_i,\ \ell_i,\ r_i,\ a_i),$$

donde

- $p_i \in \Sigma^4$ es un identificador anonimizado (`pid`) de 4 caracteres;
- $\ell_i \subseteq \mathcal{L} = \{0, \ldots, 3861\}$ es el conjunto de etiquetas temáticas del video, con $|\ell_i| \approx 3$ en promedio;
- $r_i \in \mathbb{R}^{1024}$ es el promedio temporal de las activaciones de una red Inception sobre los frames del video (`mean_rgb`);
- $a_i \in \mathbb{R}^{128}$ es su análogo para el audio (`mean_audio`).

A cada video le asignamos una *categoría gruesa*

$$c_i = \text{moda}\{\, \text{Vertical1}(j) : j \in \ell_i \,\},$$

con 25 valores posibles. Esta categoría es la referencia para evaluar las representaciones. **[PENDIENTE:** Mencionar el desbalance: Arts & Entertainment y Games concentran la mayoría.]

2.2. Metadatos desde la YouTube Data API

Los `pid` no son identificadores de YouTube. Existe una función *parcial* φ (una tabla de traducción publicada por Google) tal que $\varphi(p_i) = v_i$ es el identificador real del video. Con v_i consultamos la YouTube Data API v3 y obtenemos

$$w_i = (t_i,\ d_i,\ g_i,\ m_i,\ u_i),$$

con título t_i, descripción d_i, tags g_i, estadísticas m_i (vistas, likes, comentarios) y la URL de la miniatura u_i. A diferencia de Y, la tabla W no es un espacio vectorial: sus columnas mezclan texto, números y URLs.

No todos los videos sobreviven a estos pasos:

$$\mathcal{I} \supseteq \mathcal{I}_\varphi = \{i : \varphi(p_i) \text{ está definida}\} \supseteq \mathcal{I}_W = \{i : w_i \text{ existe}\}.$$

Tabla 1: Embudo de datos.

Etapa	Videos	%
Muestra YT-8M ($\mathcal{I}$)	41.393	100,0
Con ID real de YouTube ($\mathcal{I}_\varphi$)	37.230	89,9
Disponibles en YouTube ($\mathcal{I}_W$)	**34.788**	**84,0**

En adelante trabajamos sobre $\mathcal{I}_W$, con $n = |\mathcal{I}_W| = 34.788$.

3. Método

3.1. El espacio de embeddings

EmbeddingGemma 2 [2] es un modelo multimodal: recibe secuencias que pueden mezclar *tokens* de texto e imágenes, y las lleva a un mismo espacio. Formalmente, sea $\mathcal{V}_{\text{tok}}$ el vocabulario de tokens del modelo e $\mathcal{S}$ el conjunto de imágenes RGB. El dominio del modelo es el conjunto de secuencias finitas de tokens y/o imágenes, y su codominio es la esfera unitaria:

$$f_\theta : (\mathcal{V}_{\text{tok}} \sqcup \mathcal{S})^{\leq 8192} \longrightarrow \mathbb{S}^{767} = \{\, x \in \mathbb{R}^{768} : \|x\|_2 = 1 \,\}.$$

Un texto es el caso particular de una secuencia con solo tokens; una imagen, el de una secuencia con un solo elemento de $\mathcal{S}$. Como todos los vectores tienen norma 1, la similitud coseno se reduce al producto punto:

$$\text{sim}(x, x') = \frac{x^\top x'}{\|x\|\,\|x'\|} = x^\top x'.$$

Texto. Definimos $\tau(w_i)$ como el título, seguido de hasta 15 tags y los primeros 600 caracteres de la descripción sin URLs. El modelo recibe además un prefijo fijo que indica la tarea, $\pi_{\text{clust}} =$ `"task: clustering | query: "`. Con $\|$ la concatenación de strings,

$$x_i^T = f_\theta(\pi_{\text{clust}} \,\|\, \tau(w_i)), \qquad X^T = \begin{bmatrix} x_1^T \\ \vdots \\ x_n^T \end{bmatrix} \in \mathbb{R}^{n \times 768}.$$

El texto se trunca a 256 tokens, lo que afecta al 2,9 % de los videos.

Imagen. Sea $s_i \in \{0, \ldots, 255\}^{180\times320\times3}$ la miniatura del video. Sobre $\mathcal{I}_S \subset \mathcal{I}_W$, los videos cuya miniatura se pudo descargar ($|\mathcal{I}_S| = 34.771$),

$$x_i^I = f_\theta(s_i), \qquad X^I \in \mathbb{R}^{34771\times768}.$$

Todas las comparaciones de la Sección 4 se hacen sobre $\mathcal{I}_S$, para que cada representación se mida sobre exactamente los mismos videos. Usamos 70 tokens visuales por imagen (el valor por defecto es 280), lo que es 5 veces más rápido y cambia poco el vector (similitud 0,986 con la versión de 280 tokens).

Combinaciones de texto e imagen. Probamos dos formas de juntar ambas fuentes:

$$\underbrace{x_i^{IT} = f_\theta\big(\pi_{\text{clust}} \parallel s_i \parallel \tau(w_i)\big)}_{\text{fusión temprana: un solo input}} \qquad \underbrace{x_i^F = \frac{x_i^T + x_i^I}{\|x_i^T + x_i^I\|_2}}_{\text{fusión tardía: suma de vectores}}$$

3.2. Baselines de texto

Para justificar el uso de EmbeddingGemma 2, embebimos el mismo texto $\tau(w_i)$ con:

- **TF-IDF + SVD**: vectores de frecuencia de palabras (vocabulario de 50.000 términos) comprimidos a 768 dimensiones con SVD truncado (LSA).
- **MiniLM** [3, 4]: modelo Sentence-BERT multilingüe[1], de 384 dimensiones y 128 tokens como máximo.

3.3. Zero-shot desde la miniatura

Sea $L \in \mathbb{R}^{3806\times768}$ la matriz cuya fila j es $f_\theta(\text{nombre}_j)$, el embedding del nombre de la etiqueta j como texto. Como X^I y L viven en el mismo espacio,

$$S = X^I L^\top \in \mathbb{R}^{34771\times3806}, \qquad S_{ij} = \text{sim}(\text{imagen}_i,\ \text{etiqueta}_j).$$

La predicción para la imagen i son las k etiquetas de mayor similitud, y medimos si alguna es correcta:

$$\hat{\ell}_i^{(k)} = \operatorname*{top}_j{}_k\ S_{ij}, \qquad \text{hit@}k = \frac{1}{|\mathcal{I}_S|}\sum_{i\in\mathcal{I}_S} \mathbf{1}\big[\,\hat{\ell}_i^{(k)} \cap \ell_i \neq \varnothing\,\big].$$

3.4. Proyección y evaluación

Para visualizar usamos UMAP [5] $U : \mathbb{S}^{767} \to \mathbb{R}^3$ (métrica coseno, 15 vecinos), opcionalmente precedido de PCA a 282 componentes, que retienen el 90 % de la varianza. Cada representación X se evalúa con:

- **kNN accuracy**: qué tan bien los 15 vecinos más cercanos de x_i predicen c_i (validación cruzada de 5 folds), en el espacio original y en $U(X)$;
- **NMI**: información mutua normalizada entre los clusters de K-Means ($k = 25$) sobre $U(X)$ y las categorías c;
- **Trustworthiness** [6]: qué tan fieles son los vecindarios de $U(X)$ a los de X.

Como referencia mínima usamos el clasificador de mayoría (siempre predecir la categoría más frecuente).

[1] `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`.

4. Resultados

4.1. Texto: EmbeddingGemma 2 frente a los baselines

Tabla 2: Representaciones de texto sobre los 34.771 videos de $\mathcal{I}_S$.

Modelo	Dims	kNN original	kNN UMAP	NMI (UMAP)	Trustworthiness
TF-IDF + SVD	768	0,609	0,560	0,134	0,863
MiniLM	384	0,698	0,675	0,297	0,888
EmbeddingGemma 2	768	**0,798**	**0,771**	**0,378**	**0,956**

[**PENDIENTE:** Comentar: el orden se mantiene en todas las métricas; +19 puntos de kNN sobre TF-IDF y +10 sobre MiniLM; NMI casi triplica a TF-IDF.]

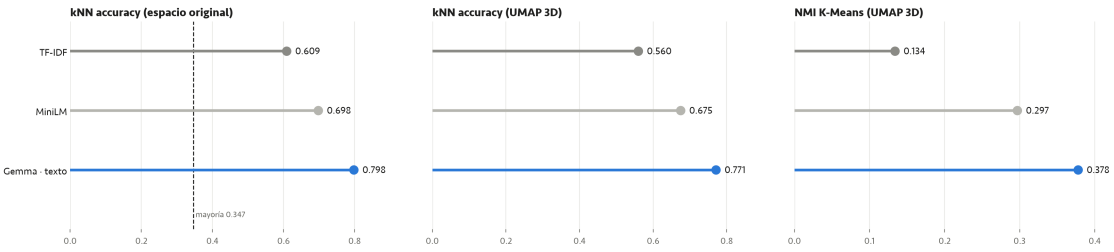


Figura 1: Comparación de modelos de embedding de texto.

Tabla 3: Proyecciones de EmbeddingGemma 2 (texto).

Proyección	Trustworthiness	Silhouette	kNN	NMI
PCA 3D	0,828	−0,133	0,643	0,325
UMAP 3D	0,956	−0,099	0,771	**0,378**
PCA 282 + UMAP 3D	**0,958**	−0,101	0,773	0,364
Original (768 dims)	–	−0,003	**0,798**	0,351
Mayoría	–	–	0,347	–

[**PENDIENTE:** PCA en 3D retiene solo el 11,2 % de la varianza. Explicar el silhouette negativo: coherencia local (kNN) sin separación global de categorías gruesas.]

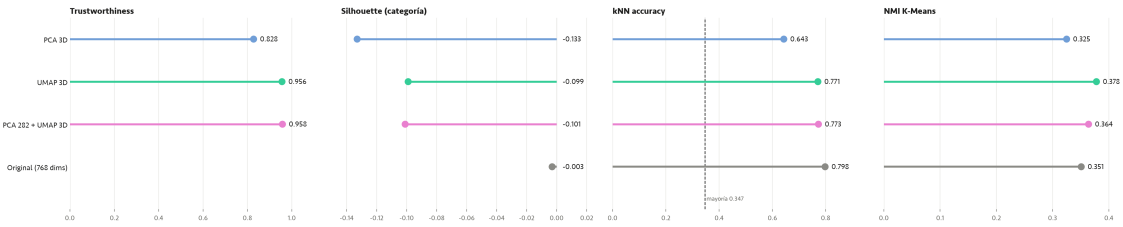


Figura 2: Calidad de las proyecciones de EmbeddingGemma 2.

4.2. Texto, imagen y fusión

Tabla 4: Comparación de las seis representaciones sobre los 34.771 videos de $\mathcal{I}_S$.

Representación	kNN original	kNN UMAP	NMI (UMAP)
Mayoría	0,347	–	–
TF-IDF + SVD	0,609	0,560	0,134
MiniLM	0,698	0,675	0,297
Texto, X^T	0,798	0,771	0,378
Imagen, X^I	0,784	0,769	0,391
Fusión temprana, X^{IT}	0,819	0,791	0,364
Fusión tardía, X^F	**0,838**	**0,823**	**0,452**

[**PENDIENTE:** Comentar: la miniatura sola casi iguala al texto; la fusión tardía es la mejor en las tres métricas y no cuesta cómputo extra; la temprana mejora al texto, pero bastante menos que la tardía (hipótesis: el texto domina el input).]

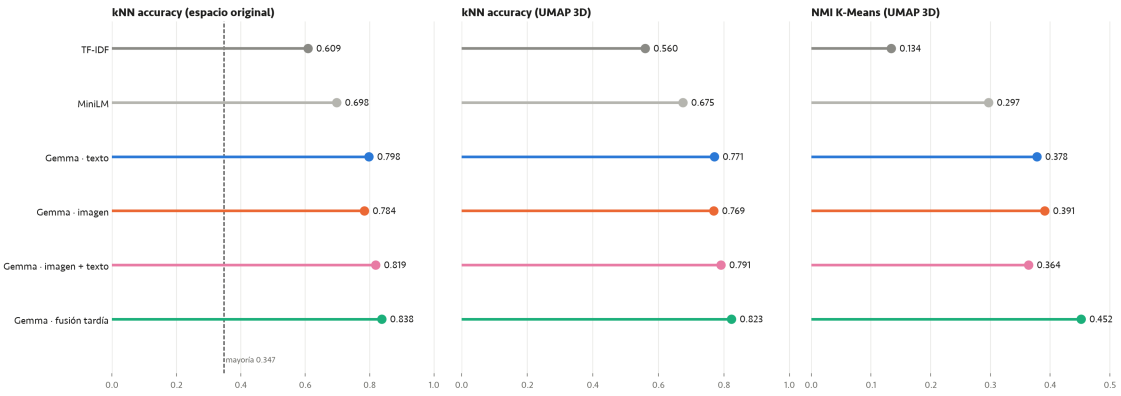


Figura 3: Texto frente a imagen y fusión.

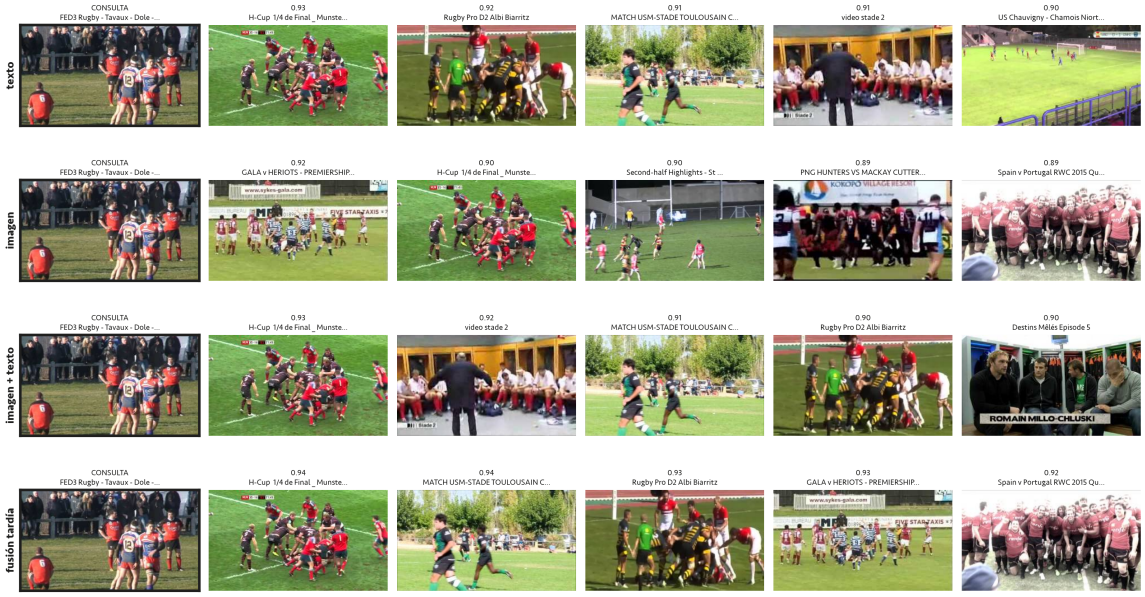


Figura 4: Vecinos más cercanos de un video en los espacios de texto, imagen y fusión.

4.3. Zero-shot

Tabla 5: Etiquetado zero-shot desde la miniatura (3.806 etiquetas candidatas).

	hit@1	hit@5	hit@10
Imagen, X^I	32,2 %	60,0 %	70,2 %

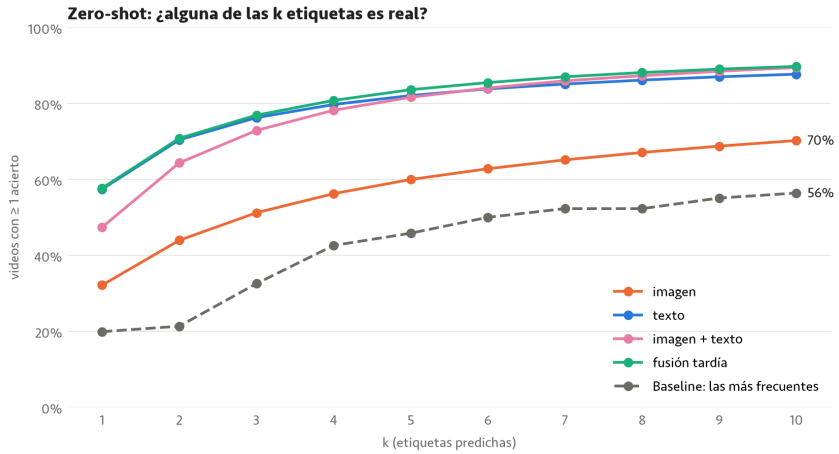


Figura 5: Fracción de videos con al menos una etiqueta real entre las k predichas.

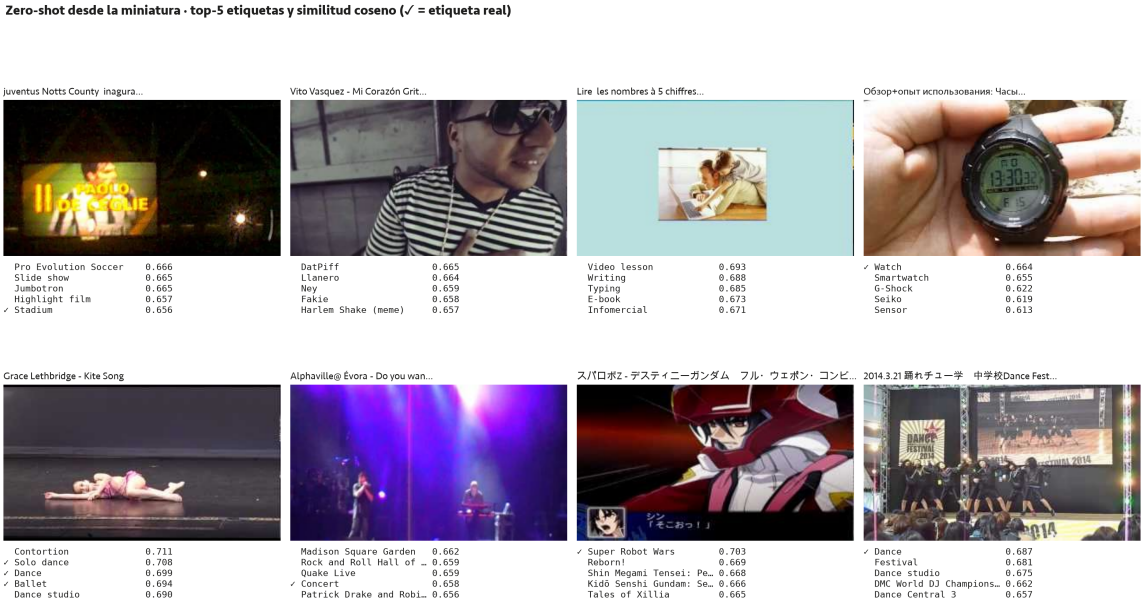


Figura 6: Ejemplos de etiquetado zero-shot (✓ = etiqueta real).

5. Discusión

[**PENDIENTE:** Desarrollar cada punto:]

- **Brecha de modalidad** [7]: la similitud media imagen–imagen es 0,67 y la imagen–texto, 0,55; en un UMAP conjunto forman dos islas separadas, que se juntan al centrar cada modalidad.

- **Sesgo por idioma**: TF-IDF agrupa por idioma más que por tema.
- **Fusión tardía frente a temprana**.

6. Limitaciones

- Las etiquetas de YT-8M fueron generadas por el sistema de anotación de YouTube a partir de "señales humanas, incluyendo metadatos y clics de búsqueda" [1]. Como en parte provienen del texto del video, la evaluación podría favorecer a los embeddings de texto frente a los de imagen.
- La categoría c_i es gruesa (25 valores) y es una sola por video, aunque el video tenga varias etiquetas: un video de un juego de carreras puede ser *Games* o *Autos & Vehicles*. Las métricas basadas en c_i son, por lo tanto, una cota inferior de la calidad de las representaciones.
- Truncación de texto (256 tokens en Gemma 2, 128 en MiniLM).
- El 16 % de los videos ya no está disponible, lo que puede sesgar la muestra.

7. Trabajo futuro

- HDBSCAN sobre UMAP y sensibilidad a `n_neighbors`.
- Usar la fusión tardía, la mejor representación medida, en el mapa de la aplicación web.
- Recomendador *fuera de la burbuja*, evaluado con novedad, diversidad y cobertura.
- Análisis causal: efecto del tema o de la miniatura sobre las vistas.

Referencias

[1] S. Abu-El-Haija *et al.* YouTube-8M: A Large-Scale Video Classification Benchmark. *arXiv:1609.08675*, 2016.

[2] Google DeepMind. EmbeddingGemma 2 (model card). `https://huggingface.co/google/embeddinggemma-2`.

[3] N. Reimers e I. Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP*, 2019.

[4] N. Reimers e I. Gurevych. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. *EMNLP*, 2020.

[5] L. McInnes, J. Healy y J. Melville. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv:1802.03426*, 2018.

[6] J. Venna y S. Kaski. Neighborhood Preservation in Nonlinear Projection Methods: An Experimental Study. *ICANN*, 2001.

[7] W. Liang *et al.* Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning. *NeurIPS*, 2022.